

# Wykład 2

## Heurystyki lokalnych ulepszeń

*Kazimierz Grygiel*



*Home Page*

*Title Page*



*Page 1 of 25*

*Go Back*

*Full Screen*

*Close*

*Quit*

# Jak skonstruować generator rozwiązań?

- Specyficzny generator dla specyficznej klasy funkcji (problemów)
- Rozpoznanie i wykorzystanie strukturalnych regularności, charakteryzujących tę klasę
- Trzy etapy konstrukcji:
  - wprowadzenie (odkrycie) struktury w zbiorze rozwiązań (*sąsiedztwo, podobieństwo, pokrewieństwo, odległość*)
  - powiązanie zależności strukturalnych z ilościowymi (określenie rodzaju regularności)
  - sformułowanie strategii heurystycznego przeszukiwania wykorzystującej hipotetyczne regularności
- *Uwaga*: trzeba pamiętać, że nasze hipotezy będą często *zawodne*; inaczej moglibyśmy je sformułować w postaci twierdzenia i skonstruować na ich podstawie „porządną” algorytm

[Home Page](#)[Title Page](#)

Page 2 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Sąsiedztwo, przekształcenia modyfikujące

- Podejście strukturalne: rozkład rozwiązania na komponenty
- Odległość rozwiązań: liczba „różnic”
- Sąsiedztwo rozwiązania  $x$ :

$$N(x) = \{y \in S : d(x, y) = 1\}$$

- Podejście operacyjne: przekształcenia generujące sąsiedztwo  
(*przekształcenia modyfikujące, ruchy, mutacje*)

$$\Phi = \{\phi_i : S \rightarrow S, i \in I\}$$


- Sąsiedztwo rozwiązania  $x$ :

$$N(x) = \{\phi_i(x), i \in I\}$$

[Home Page](#)[Title Page](#)[Page 3 of 25](#)[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Iterowane przeszukiwanie lokalne — idea

- Ogólna koncepcja:
  - „punkt wypadowy” i penetracja sąsiedztwa
  - podążanie za „tropem”, zmiana punktu wypadowego
- Schemat formalny pojedynczej „rundy” algorytmu (heurystyka przeszukiwania z ograniczoną pamięcią)



$(x_b, x'_b)$  — rozwiązania bieżące)

- Sposób wyboru nowego rozwiązania bieżącego określa *reguła selekcji*



Home Page

Title Page



Page 4 of 25

Go Back

Full Screen

Close

Quit

# Iterowane przeszukiwanie lokalne — opis

- Wybieramy rozwiązanie początkowe, które staje się *rozwiązaniem bieżącym*
- Generujemy pewną liczbę rozwiązań z sąsiedztwa rozwiązania bieżącego i spośród nich wybieramy kolejne rozwiązanie bieżące
- Powtarzamy ostatni krok pewną liczbę razy, zapamiętując za każdym razem najlepsze otrzymane rozwiązanie
- Jako wynik (aproksymację optimum) przyjmujemy najlepsze zapamiętane rozwiązanie, czyli

$$x_{opt}(K) = \text{opt}_f\{x_0, x_1, \dots, x_K\}$$

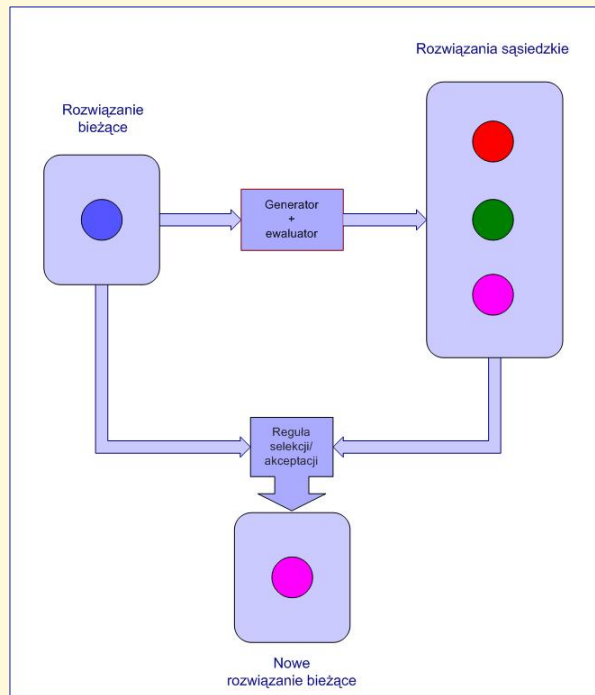
gdzie  $K$ : liczba wygenerowanych rozwiązań

[Home Page](#)[Title Page](#)

Page 5 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Schemat działania



[Home Page](#)

[Title Page](#)



*Page 6 of 25*

[Go Back](#)

[Full Screen](#)

[Close](#)

[Quit](#)

# Heurystyki lokalnych ulepszeń

- Jak rozpoznawać „trop” (tzn. jak wybierać nowe rozwiązanie bieżące)?
  - jak zapewnić, żeby rozwiązania bieżące nie powtarzały się, unikając ich rejestracji?
  - jak zapewnić, żeby ciąg rozwiązań bieżących zmierzał do rozwiązania optymalnego?
- *Pomysł*: metoda dojścia na szczyt we mgle — iść stale pod górę
- *Realizacja*: monotoniczna reguła selekcji – podstawa *heurystyki lokalnych ulepszeń*
- Formalnie: heurystyka iterowanego przeszukiwania lokalnego jest heurystyką lokalnych ulepszeń, jeżeli w każdej iteracji rozwiązanie bieżące albo zostaje ulepszone, albo nie ulega zmianie
- Synonim: *algorytm wspinaczki*



[Home Page](#)

[Title Page](#)



Page 7 of 25

[Go Back](#)

[Full Screen](#)

[Close](#)

[Quit](#)

# Konsekwencje selekcji monotonicznej

- Co zyskujemy (lub nie)?
  - pierwszy problem rozwiązany całkowicie
  - drugi problem rozwiązany częściowo i niezadowolająco: pułapka lokalnych szczytów
- Formalnym odpowiednikiem „lokalnego szczytu” jest pojęcie *optimum lokalnego*: rozwiązanie  $x$  jest *optimum lokalnym*, jeśli w jego sąsiedztwie  $N(x)$  nie istnieje rozwiązanie *lepsz*e
- *Wniosek*:

Metoda wspinaczki działa, jeśli jest tylko jeden szczyt; w przeciwnym przypadku może się załamać
- Uwaga: „Teren równinny” (*plateau*) w „krajobrazie” optymalizacyjnym składa się z samych *optimów* lokalnych!

[Home Page](#)[Title Page](#)

Page 8 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)



# Deterministyczne reguły selekcji

- Notacja:  $R(x, f, \Phi)$ , gdzie

$x$ : rozwiązanie bieżące

$f$ : funkcja oceny

$\Phi$ : rodzina przekształceń modyfikujących

- SAHC (Steepest Ascent Hill Climbing):

$R(x, f, \Phi) :=$  *najlepsze (ze względu na  $f$ ) rozwiązanie w ciągu*

$$x, \phi_1(x), \dots, \phi_{|I|}(x)$$

*(w przypadku niejednoznaczności: pierwsze z nich)*

- NAHC (Next Ascent Hill Climbing):

$R(x, f, \Phi) :=$  *pierwsze (o ile istnieje) rozwiązanie w ciągu*

$$\phi_1(x), \dots, \phi_{|I|}(x)$$

*lepsze (ze względu na  $f$ ) niż  $x$ ; w przeciwnym przypadku  $x$*

[Home Page](#)[Title Page](#)

Page 9 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Zrandomizowane heurystyki lokalnych ulepszeń

- Zrandomizowany generator rozwiązań: wybór losowego rozwiązania z sąsiedztwa rozwiązania bieżącego
- Prosta realizacja: *operator modyfikacji*  $\phi_\xi$ , gdzie  $\xi$  — zmienna losowa o wartościach ze zbioru indeksowego  $I$  (Inaczej mówiąc, za każdym razem losujemy jedno z przekształceń modyfikujących z rodziny  $\Phi$ )<sup>1</sup>
- Reguła selekcji redukuje się do *reguły akceptacji*: przyjąć lub odrzucić nowe rozwiązanie
- Konieczne jest *zewnętrzne* kryterium zatrzymania (niemożność sprawdzenia, czy wyczerpano wszystkie elementy sąsiedztwa)

---

<sup>1</sup> *Uwaga terminologiczna: Operatorem będziemy tu nazywać losowe przekształcenie z danej rodziny przekształceń*

[Home Page](#)[Title Page](#)[Page 10 of 25](#)[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Formalizacja

- Relacje „porządku jakościowego”:

- porządek rosnący

$$x' \prec_f x'' \equiv \begin{cases} f(x') < f(x'') & \text{(maksymalizacja)} \\ f(x') > f(x'') & \text{(minimalizacja)} \end{cases}$$

(czytamy:  $x'$  jest gorsze niż  $x''$  ze względu na  $f$ )

- porządek malejący

$$x' \succ_f x'' \equiv x'' \prec_f x'$$

(czytamy:  $x'$  jest lepsze niż  $x''$  ze względu na  $f$ )

- Podzbiór lepszych sąsiadów:

$$N^+(x) = \{z \in N(x) : x \prec_f z\}$$

- Rozwiązanie  $x$  jest *optimum lokalnym*, jeśli

$$x \not\prec_f z \text{ dla dowolnego } z \in N(x)$$

Warunek równoważny:  $N^+(x) = \emptyset$

[Home Page](#)[Title Page](#)

Page 11 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Schemat zrandomizowanej heurystyki lokalnych ulepszeń

- Oznaczenia:

$S$  – zbiór rozwiązań zadania

$\phi_\xi$  – operator modyfikacji na  $S$

$\prec_f$  – relacja porządku jakościowego na  $S$  (ze względu na funkcję  $f$ )

- Algorytm:

begin

$x :=$  losowy element z  $S$ ;

    repeat

$z := \phi_\xi(x)$ ;

        if  $x \prec_f z$  then  $x := z$

    until warunek zatrzymania;

    return  $x$

end



[Home Page](#)

[Title Page](#)



Page 12 of 25

[Go Back](#)

[Full Screen](#)

[Close](#)

[Quit](#)

# Czas oczekiwania na poprawę rozwiązania

- Algorytm: zrandomizowana heurystyka lokalnych ulepszeń
- Oznaczenia:

$$p_s(x) = \mathbf{P} \{ \phi_\xi(x) \in N^+(x) \}$$

$$q_s(x) = 1 - p_s(x)$$

$T_s(x)$ : czas oczekiwania na poprawę rozwiązania

- Wówczas

$$\mathbf{P} \{ T_s(x) = t \} = q_s^{t-1}(x) p_s(x)$$

(rozkład geometryczny)

$$\mathbf{E}T_s(x) = \begin{cases} 1/p_s(x) & \text{jeśli } p_s(x) > 0 \\ +\infty & \text{w p. p.} \end{cases}$$

[Home Page](#)[Title Page](#)

Page 13 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Charakteryzacja wyników

- Jakie rozwiązanie znajduje heurystyka lokalnych ulepszeń (ogólniej: monotoniczna)?
- Wariant deterministyczny:
  - przestrzeń rozwiązań rozpada się na rozłączne *obszary przyciągania* optimów lokalnych
  - wynik zależy wyłącznie od punktu startowego
  - optima lokalne = punkty stałe reguły selekcji  $R$
- Wariant zrandomizowany:
  - nie ma obszarów przyciągania
  - algorytm zachowuje się jak *pochłaniający łańcuch Markowa*
  - optima lokalne = stany pochłaniające
- Kiedy heurystyki monotoniczne znajdują optimum globalne niezależnie od punktu startowego?
- Gdy wszystkie optima lokalne są globalne (inaczej: gdy lokalne ulepszenia zawsze zbliżają do celu)



[Home Page](#)

[Title Page](#)



Page 14 of 25

[Go Back](#)

[Full Screen](#)

[Close](#)

[Quit](#)

# Uogólnione struktury sąsiedztwa

- Skąd biorą się optima lokalne?
- Odpowiedź: sami je wprowadziliśmy, ograniczając przeszukiwanie do sąsiedztwa rozwiązania bieżącego
- Jak złagodzić ten problem?
- Hierarchia sąsiedztw:

$$k\text{-sąsiedztwo rozwiązania } x = \{y \in S : \rho(x, y) \leq k\},$$

gdzie  $\rho(\cdot, \cdot)$  — odległość (metryka) w  $S$

- Mechanizm uprzywilejowania *bliskiego* sąsiedztwa: stopniowe oddalanie się od punktu wyjścia
- Heurystyki zrandomizowane: *stochastyczna lokalność* operatora; prawdopodobieństwo malejące wraz ze wzrostem odległości („zasięgu” operatora)

[Home Page](#)[Title Page](#)

Page 15 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Reprezentacje: przestrzeń wektorów zerojedynkowych

- Przestrzeń wektorów zerojedynkowych

$$B_m = \{x = (x_1, x_2, \dots, x_m), \text{ gdzie } x_j \in \{0, 1\}\}$$

z metryką Hamminga:  $d_H(x, y) = \sum_{j=1}^m |x_j - y_j|$

- Przekształcenia modyfikujące: *mutacje punktowe*

$$\Phi = \{\phi_j(x_1, \dots, x_j, \dots, x_m) = (x_1, \dots, 1 - x_j, \dots, x_m), j \in I\}$$

gdzie  $I = \{1, 2, \dots, m\}$

- *Operator mutacji punktowej*  $\phi_\xi$ :

gdzie  $\xi$  — zmienna losowa o rozkładzie jednostajnym na  $I$ , tj.

$$\mathbf{P} \{\xi = j\} = \frac{1}{m} \text{ dla } j \in I$$

[Home Page](#)[Title Page](#)

Page 16 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)



# Przykład: analiza czasu oczekiwania na optimum



- $p_s(x) = \frac{|N^+(x)|}{|N(x)|}$  dla  $x \in B_m$ ,  $|N(x)| = m$
- funkcja oceny:  $f(x) = \sum_{i=1}^m x_i$ , zadanie maksymalizacji
- optimum globalne:  $(1, 1, \dots, 1)$  (brak innych optimów lokalnych)
- rozwiązanie startowe:  $x^0 = (0, 0, \dots, 0)$
- $p_s(x^k) = (m-k)/m$ , więc

$$\mathbf{E}T_s(x^k) = m/(m-k) \text{ dla } k=0, 1, \dots, m-1$$

- całkowity średni czas oczekiwania:

$$m \sum_{k=0}^{m-1} \frac{1}{m-k} = mH_m \cong m \ln(m)$$

[Home Page](#)[Title Page](#)[Page 17 of 25](#)[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Mutacja Bernoulliego

- Mutacje wielopunktowe (wg maski):

$$\Phi = \{\phi_i(x) = x \oplus i, i \in B_m\}$$

gdzie  $i$  — *maska mutacyjna*,  $\oplus$  — dodawanie modulo 2 po współrzędnych

- Operator mutacji Bernoulliego  $\phi_\xi$ :  
 $\xi$  — wektor losowy o wartościach z  $B_m$ , przy czym

$$\mathbf{P} \{\xi = i\} = p^{/i/} (1-p)^{m-/i/}$$

gdzie  $p$  — *punktowe prawdopodobieństwo mutacji*

$/i/$  — liczba jedynek w masce  $i$

- Średni zasięg operatora (oczekiwana liczba zmutowanych pozycji w wektorze  $x$ ):  $mp$
- Rozsądne wartości:  $0 < p < 0.5$
- Uwaga:  $p = 0.5$  generuje rozkład jednostajny na  $S$

[Home Page](#)[Title Page](#)

Page 18 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Mutacja Bernoulliego: objaśnienia

- Jak działa maska mutacyjna?

$x$	0	0	1	1
$i$	0	1	0	1
$x \oplus i$	0	1	1	0
$p_i$	$q$	$p$	$q$	$p$

- *Interpretacja*: Jedynka w masce oznacza zajście mutacji punktowej na danej pozycji
- *Prawdopodobieństwo maski* (dla tego przykładu):  $p^2q^2$  ( $q = 1 - p$ )
- Uwaga końcowa: Mutacja Bernoulliego z  $p < 0.5$  jest przykładem operatora stochastycznie lokalnego!

[Home Page](#)[Title Page](#)[Page 19 of 25](#)[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Reprezentacje binarne: implementacja

- Implementacja tablicowa: jeden bajt na zapamiętanie jednego bitu (spore marnotrawstwo, ale bez ograniczeń)
- Implementacja całkowitoliczbowa: możliwa w zakresie umiarkowanych długości reprezentacji
- Przykładowa implementacja w Pascalu:

```
const
    L = 30; { długość chromosomu }
    N = Integer(1) shl L; { N = 2^L }
type
    Chromosom = 0..(N-1);
```

- Operacje na bitach
  - dodawanie wektorowe modulo 2 (operacja  $\oplus$ ): **xor**
  - przesunięcie o jeden bit w lewo / w prawo: **shl** / **shr**

[Home Page](#)[Title Page](#)

Page 20 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# „Zegar mutacyjny”

- Dla małych wartości  $p$  można zastosować efektywną implementację operatora mutacji Bernoulliego, opartą na następującym twierdzeniu:

*Jeżeli  $p$  jest prawdopodobieństwem sukcesu dla nieograniczonego ciągu prób Bernoulliego oraz  $U$  — zmienną losową o rozkładzie jednostajnym na odcinku  $[0, 1]$ , to  $K = \lfloor \ln(U) / \ln(1 - p) \rfloor$  jest zmienną losową reprezentującą liczbę porażek przed pierwszym sukcesem*

- Zamiast dokonywać próby losowej dla każdej pozycji wektora, losujemy miejsca, w których zachodzi mutacja punktowa
- Gdy mutacje są rzadkie, daje to znaczną oszczędność czasu

[Home Page](#)[Title Page](#)[Page 21 of 25](#)[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Reprezentacje: przestrzeń wektorów rzeczywistoliczbowych

- Przestrzeń wektorów rzeczywistoliczbowych

$$\mathcal{R}^m = \{x = (x_1, x_2, \dots, x_m), \text{ gdzie } x_j \in \mathcal{R}\}$$


z metryką euklidesową lub miejską

- Przekształcenia modyfikujące: mutacje addytywne:  $\phi_u(x) = x + u$ , gdzie  $x, u \in \mathcal{R}^m$
- Operator mutacji gaussowskiej  $\phi_\xi(x) = x + \xi$ :  
 $\xi$  — wektor losowy o  $m$ -wymiarowym rozkładzie normalnym o średniej 0 i macierzy kowariancji  $\mathbf{C}$ .
- Wariant uproszczony  $\mathbf{C} = \mathbf{D}^2$  (brak korelacji)
- Wtedy  $F(x_1, \dots, x_m) = \prod_{i=1}^m F_i(x_i)$ ,  
gdzie  $F_i(x) = (\sigma_i \sqrt{2\pi})^{-1} \int_{-\infty}^x e^{-\frac{t^2}{2\sigma_i^2}} dt$

[Home Page](#)[Title Page](#)[Page 22 of 25](#)[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Rozkład normalny (jednowymiarowy)

- Notacja:  $\xi \sim N(a, \sigma)$  — zmienna losowa  $\xi$  ma rozkład normalny z parametrami  $a, \sigma$
- Parametry:  $a$ : wartość oczekiwana,  $\sigma$ : odchylenie standardowe ( $\sigma^2$  – wariancja)
- Funkcja gęstości:  $g(t) = \frac{1}{\sigma\sqrt{2\pi}} e^{\frac{-(t-a)^2}{2\sigma^2}}$  (*krzywa Gaussa*)

[Home Page](#)[Title Page](#)[Page 23 of 25](#)[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)

# Charakterystyka mutacji gaussowskiej

- Warian standardowy: mutacje niezależne dla każdej współrzędnej rozwiązania
- Rozkład zasięgu mutacji ( $\mathbf{P} \{|\xi| < k\sigma\}$ ):

odchylenie	% przypadków
$0,67\sigma$	50,0
$\sigma$	68,3
$2\sigma$	95,6
$3\sigma$	99,7

- Średni zasięg (oczekiwana długość „kroku mutacyjnego”):

$$\mathbf{E}|\xi| = \sigma\sqrt{\frac{2}{\pi}} \cong 0,80\sigma$$

- Uwaga: mutacja gaussowska jest także przykładem operatora stochastycznie lokalnego

[Home Page](#)[Title Page](#)[Page 24 of 25](#)[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)



# Generowanie liczb losowych o rozkładzie normalnym

- Rozkład  $N(0, 1)$  (metoda Boxa-Mullera):

*Jeżeli  $U_1, U_2$  są niezależnymi zmiennymi losowymi o rozkładzie jednostajnym na przedziale  $(0, 1)$ , to*

$$X_1 = \sqrt{-2 \ln U_1} \cos(2\pi U_2)$$

$$X_2 = \sqrt{-2 \ln U_1} \sin(2\pi U_2)$$

*są niezależnymi zmiennymi losowymi o rozkładzie normalnym  $N(0, 1)$*

- Rozkład  $N(a, \sigma)$ :

$$Y = a + \sigma X$$

gdzie  $X$  – zmienna losowa o rozkładzie  $N(0, 1)$

[Home Page](#)[Title Page](#)

Page 25 of 25

[Go Back](#)[Full Screen](#)[Close](#)[Quit](#)